COMPUTACIÓN CIENTÍFICA

Regresión lineal múltiple

Estimación del tiempo de ejecución de un solver de sistemas dispersos

Ejercicio propuesto y solución completa

Curso: Modelos matemáticos de la ciencia II
Área: Escuela Profesional de Computación Científica
Material principal: Semana 9 y extracto de regresión múltiple del proyecto del curso.
Fecha: 28 de octubre de 2026

Naturaleza del ejercicio. Los 48 registros son simulados con semilla fija. Se analiza un escenario de benchmarking; no se presentan mediciones de hardware real. El HTML complementario funciona sin conexión y conserva el mismo modelo del informe.

Resumen

Se propone un problema reproducible de predicción del tiempo de un solver iterativo disperso. Las regresoras son el trabajo acumulado sobre elementos no nulos y el volumen escrito en puntos de control. Se generan 48 observaciones, de las cuales 36 se destinan a estimación y 12 a prueba. Mediante mínimos cuadrados ordinarios (MCO) se obtiene

$$\widehat{T} = 1.414171 + 0.160782W + 1.385309V.$$

El ajuste alcanza $R^2 = 0.9792$ y un error estándar residual de 0.6036 segundos. En prueba, el RMSE es 0.5707 segundos. Se desarrollan las operaciones de estimación, ANOVA, inferencia individual y conjunta, análisis de residuos, validación y simulación. Los resultados son coherentes con el mecanismo generador; su uso en otro equipo requeriría mediciones y validación adicionales.

Criterio de presentación. Se escribe primero el problema y luego se resuelve, mostrando fórmula, sustitución, decisión e interpretación, siguiendo el enfoque del curso. Se usa β_1 como intercepto y β_2, β_3 como pendientes, igual que en la semana 9 [1, 2].

Índice

1. Planteamiento del problema . . . 2
2. Recolección y presentación de datos . . . 2
2.1. Diccionario de variables y unidad de observación . . . 2
2.2. Origen reproducible de los registros . . . 3
2.3. Protocolo propuesto para recolectar datos reales . . . 3
3. Formulación del modelo matemático . . . 3
4. Estimación de los coeficientes de regresión . . . 4
4.1. Función objetivo y ecuaciones normales . . . 4
4.2. Solución mediante desviaciones respecto de las medias . . . 4
5. Ecuación de regresión obtenida . . . 4
6. Cálculo y evaluación de residuos . . . 5
7. Evaluación del ajuste del modelo . . . 5
8. Evaluación de los supuestos del modelo . . . 6
9. Pruebas estadísticas de los residuos . . . 7
10. Pruebas de hipótesis de los coeficientes de regresión . . . 8
11. Prueba de hipótesis global del modelo . . . 8
12. Validación del modelo . . . 9
12.1. Estrategia sin fuga de información . . . 9
12.2. Interpretación de la prueba reservada . . . 9
13. Predicción mediante el modelo . . . 10
14. Simulación y visualización . . . 10
14.1. Experimento Monte Carlo reproducible . . . 10
14.2. Uso de la aplicación HTML . . . 11
15. Análisis y discusión de resultados . . . 12
16. Conclusiones . . . 12
17. Referencias bibliográficas . . . 13
A. Datos completos y residuos . . . 14
B. Intervalos y errores en la prueba reservada . . . 15
C. Trazabilidad, notación y reproducción . . . 15

1. Planteamiento del problema

Enunciado del ejercicio

Un laboratorio utiliza un solver iterativo para resolver sistemas lineales dispersos $A\boldsymbol{z} = \boldsymbol{b}$. Necesita estimar el tiempo total de un lote antes de programarlo en una estación de trabajo. El algoritmo y el equipo se mantienen fijos. En cada lote se conoce el número total de elementos no nulos procesados durante las iteraciones y el volumen escrito como puntos de control o *checkpoints*.

Se dispone de 48 registros simulados. Para cada registro se observan el tiempo total T en segundos, el trabajo W en millones de elementos no nulos procesados y el volumen escrito V en GB decimales. Los registros 1–36 se reservan para ajuste y los registros 37–48 para prueba. Con $\alpha = 0.05$:

1. Formular y estimar un modelo de regresión múltiple de T respecto de W y V; interpretar sus coeficientes.
2. Calcular residuos, evaluar ajuste y supuestos, y realizar contrastes individuales y globales.
3. Validar el modelo sin utilizar los datos de prueba para ajustar parámetros.
4. Predecir el tiempo cuando $W = 60$ millones y $V = 2.5$ GB, con intervalos del 95 %.
5. Simular ajustes repetidos y construir una herramienta interactiva que permita probar el modelo.

Justificación computacional y alcance

En un método disperso, el costo acumulado depende del trabajo efectivamente procesado. Si una matriz tiene m elementos no nulos y se ejecutan q iteraciones con un recorrido de la matriz por iteración, entonces $W = mq/10^6$. Por ejemplo, $m = 10^6$ y $q = 60$ producen $W = 60$. Si cada iteración requiere varios recorridos, se deben contabilizar todos. Los demás costos que escalan de forma estable con ese trabajo quedan absorbidos en el coeficiente efectivo.

La entrada y salida aporta otro costo que se aproxima por una tasa efectiva constante. El modelo es una aproximación aditiva para una implementación y un rango acotados. No describe cambios de complejidad, saturación de memoria, comunicación entre nodos o superposición variable entre cómputo y escritura. Su objetivo es didáctico y predictivo dentro del escenario simulado, sin atribuir causalidad empírica.

2. Recolección y presentación de datos

2.1. Diccionario de variables y unidad de observación

La unidad de observación es un lote completo de ejecución, con su trabajo total y volumen total. $Y = T$ es cuantitativa continua de razón. $X_2 = W$ es una medida de conteo escalada, y $X_3 = V$ es cuantitativa continua de razón.

Símbolo	Definición operativa	Unidad
$Y_i = T_i$	Tiempo de cómputo y escritura del lote	segundos
$X_{2i} = W_i$	Trabajo acumulado sobre no nulos	millones de elementos
$X_{3i} = V_i$	Volumen total de checkpoints escritos	GB (10^9 bytes)

2.2. Origen reproducible de los registros

Se usa `numpy.random.default_rng(20261028)`. En este orden se generan 48 enteros uniformes $W \in \{20, \dots, 100\}$, 48 enteros uniformes $J \in \{5, \dots, 45\}$ y se define $V = J/10$. Luego se generan 48 errores independientes normales de desviación 0.55 segundos:

$$T_i = \text{redondear}_{0.001}\left(2 + 0.16W_i + 1.20V_i + u_i\right), \qquad u_i \overset{\text{iid}}{\sim} N(0, 0.55^2).$$

Los coeficientes del generador se conocen para evaluar la simulación, pero **no se usan para estimar el modelo**. El pequeño redondeo introduce una diferencia despreciable respecto de una normal exacta. No se eligió una semilla buscando que las pruebas aprobaran. El orden de generación se conserva como orden de ejecución simulado.

La partición 36/12 se fija antes del ajuste. No hay valores faltantes. Los valores se conservaron como fueron generados, sin eliminar observaciones. El archivo `datos_y_residuos.csv` y el anexo A contienen los 48 registros. En las 36 filas de ajuste los rangos efectivos son $W \in [21.0, 100.0]$ y $V \in [0.6, 4.5]$.

Variable	Media	Desviación muestral	Mínimo	Máximo
Trabajo W	54.472	24.089	21.000	100.000
Volumen V	2.492	1.173	0.600	4.500
Tiempo T	13.624	4.067	6.186	21.599

La correlación de Pearson entre las regresoras es $r_{WV} = -0.1148$. Esta correlación describe el diseño; no es una prueba de causalidad.

2.3. Protocolo propuesto para recolectar datos reales

Para sustituir la simulación por mediciones: fijar equipo, solver, precondicionador, número de hilos y versiones; registrar frecuencia y condiciones térmicas; hacer calentamientos fuera del cronometraje; variar W y V con orden aleatorio; medir el tiempo con un reloj monotónico de alta resolución; sincronizar al terminar la escritura para evitar medir solo el búfer; repetir cada configuración y conservar las repeticiones individuales. Definir expresamente si se incluye inicialización. Se deben registrar fallos de convergencia y cargas externas, y justificar cualquier exclusión antes de analizar resultados. Si hay agrupamientos por sesión, las particiones de validación deben respetarlos.

3. Formulación del modelo matemático

La función de regresión poblacional es

$$Y_i = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + u_i, \qquad E(u_i \mid X_{2i}, X_{3i}) = 0. \tag{1}$$

Así, $E(Y_i \mid W_i, V_i) = \beta_1 + \beta_2 W_i + \beta_3 V_i$. Se estiman $k = 3$ parámetros con $n = 36$ filas de ajuste y quedan $n - k = 33$ grados de libertad. En notación matricial,

$$\boldsymbol{y} = X\boldsymbol{\beta} + \boldsymbol{u}, \quad X = \begin{bmatrix} 1 & W_1 & V_1 \\ \vdots & \vdots & \vdots \\ 1 & W_{36} & V_{36} \end{bmatrix}, \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \end{bmatrix}.$$

Se espera $\beta_2 > 0$ y $\beta_3 > 0$, aunque los contrastes se plantean bilateralmente. El modelo es lineal en los parámetros y usa una variable de trabajo que ya incorpora la interacción entre no nulos e iteraciones. La normalidad de los errores se añade para la inferencia exacta clásica, pero no es necesaria para calcular MCO.

4. Estimación de los coeficientes de regresión

4.1. Función objetivo y ecuaciones normales

MCO minimiza

$$Q(\boldsymbol{\beta}) = \sum_{i=1}^{36} (Y_i - \beta_1 - \beta_2 W_i - \beta_3 V_i)^2.$$

Derivando: $\partial Q/\partial \beta_1 = -2\sum \hat{u}_i = 0$, $\partial Q/\partial \beta_2 = -2\sum W_i \hat{u}_i = 0$ y $\partial Q/\partial \beta_3 = -2\sum V_i \hat{u}_i = 0$. Por tanto,

$$X^{\mathsf{T}} X \widehat{\boldsymbol{\beta}} = X^{\mathsf{T}} \boldsymbol{y}, \qquad \widehat{\boldsymbol{\beta}} = (X^{\mathsf{T}} X)^{-1} X^{\mathsf{T}} \boldsymbol{y}.$$

Los productos obtenidos exclusivamente con las 36 filas de ajuste son

$$X^{\mathsf{T}} X = \begin{bmatrix} 36.000 & 1961.000 & 89.700 \\ 1961.000 & 127129.000 & 4772.600 \\ 89.700 & 4772.600 & 271.690 \end{bmatrix}, \qquad X^{\mathsf{T}} \boldsymbol{y} = \begin{bmatrix} 490.465 \\ 29824.713 \\ 1270.572 \end{bmatrix}.$$

El rango de X es 3. Para computar se utiliza la solución por pseudoinversa basada en SVD de `statsmodels.OLS`, evitando resolver el problema mediante una inversión explícita de las ecuaciones normales. La inversa se muestra para explicar la teoría y obtener las varianzas.

4.2. Solución mediante desviaciones respecto de las medias

Sean $w_i = W_i - \bar{W}$, $v_i = V_i - \bar{V}$ y $y_i = Y_i - \bar{Y}$. Las medias son $\bar{W} = 54.472222$, $\bar{V} = 2.491667$ y $\bar{Y} = 13.624028$. Se calculan

$$\begin{aligned} S_{ww} &= \sum w_i^2 = 20308.972222, & S_{vv} &= \sum v_i^2 = 48.187500, \\ S_{wv} &= \sum w_i v_i = -113.558333, & S_{wy} &= \sum w_i y_i = 3107.994528, \\ S_{vy} &= \sum v_i y_i = 48.496508. \end{aligned}$$

Al eliminar el intercepto quedan $S_{ww}\hat{\beta}_2 + S_{wv}\hat{\beta}_3 = S_{wy}$ y $S_{wv}\hat{\beta}_2 + S_{vv}\hat{\beta}_3 = S_{vy}$. Con $D = S_{ww}S_{vv} - S_{wv}^2 = 965743.103889 > 0$:

$$\begin{aligned} \hat{\beta}_2 &= \frac{S_{wy}S_{vv} - S_{vy}S_{wv}}{D} = \frac{(3107.994528)(48.187500) - (48.496508)(-113.558333)}{965743.103889} = 0.160782, \\ \hat{\beta}_3 &= \frac{S_{vy}S_{ww} - S_{wy}S_{wv}}{D} = \frac{(48.496508)(20308.972222) - (3107.994528)(-113.558333)}{965743.103889} = 1.385309, \\ \hat{\beta}_1 &= \bar{Y} - \hat{\beta}_2 \bar{W} - \hat{\beta}_3 \bar{V} \\ &= 13.624028 - (0.160782)(54.472222) - (1.385309)(2.491667) = 1.414171. \end{aligned}$$

Las cifras mostradas están redondeadas; los cálculos de archivos y aplicación utilizan precisión completa.

5. Ecuación de regresión obtenida

$$\boxed{\widehat{T} = 1.414171 + 0.160782 W + 1.385309 V \quad \text{segundos.}} \tag{2}$$

Manteniendo V fijo, un millón adicional de elementos no nulos procesados se asocia con 0.160782 segundos más. Un aumento de diez millones se asocia con 1.6078 segundos. Manteniendo W fijo, cada GB adicional escrito se asocia con 1.385309 segundos más.

El intercepto es el tiempo estimado en $W = V = 0$, punto fuera del dominio observado. Por ello se interpreta como un parámetro de ajuste y no como una medición del costo de arranque del equipo. La pendiente de escritura equivale a una tasa efectiva aproximada de $1/\hat{\beta}_3 = 0.7219$ GB/s; se trata de una interpretación del escenario simulado, no de una especificación real del disco.

6. Cálculo y evaluación de residuos

Para las filas de ajuste, $\hat{u}_i = Y_i - \widehat{Y}_i$. Un residuo positivo indica que el tiempo observado superó al estimado. Para la primera observación:

$$\widehat{T}_1 = 1.414171 + (0.160782)(33.000000) + (1.385309)(4.500000) = 12.953854,$$
$$\hat{u}_1 = 12.300000 - 12.953854 = -0.653854 \text{ s}, \qquad \hat{u}_1^2 = 0.427525 \text{ s}^2.$$

La suma de cuadrados residual es

$$SC_{\text{res}} = \sum_{i=1}^{36} \hat{u}_i^2 = 12.0247, \quad \hat{\sigma}^2 = \frac{SC_{\text{res}}}{36-3} = 0.364385, \quad s = \sqrt{\hat{\sigma}^2} = 0.6036 \text{ s}.$$

Se verifica $\sum \hat{u}_i \simeq 0$ y $X^{\mathsf{T}}\hat{\boldsymbol{u}} \simeq \mathbf{0}$ numéricamente. Son identidades de MCO con intercepto; no demuestran la exogeneidad ni la media condicional cero del error poblacional.

Para comparar residuos con distinta precisión se calculan

$$h_i = \boldsymbol{x}_i^{\mathsf{T}}(X^{\mathsf{T}}X)^{-1}\boldsymbol{x}_i, \quad r_i = \frac{\hat{u}_i}{s\sqrt{1-h_i}}, \quad D_i = \frac{r_i^2}{k}\frac{h_i}{1-h_i}.$$

r_i es el residuo estandarizado interno y D_i la distancia de Cook. El máximo $|r_i|$ es 1.9971, el máximo leverage es 0.1595 y la máxima distancia de Cook es 0.2165. No hay filas con $|r_i| > 2$ ni con $h_i > 2k/n = 0.1667$. Las filas 2, 12, 24, 31 superan $4/n = 0.1111$ en Cook. Estos cortes son señales de revisión, no reglas automáticas de eliminación.

Se hizo un análisis de sensibilidad exploratorio retirando conjuntamente esas cuatro filas: las pendientes se vuelven 0.161449 y 1.288247, con cambios relativos de 0.41 % y −7.01 %. Las diferencias merecen reportarse, aunque el signo positivo se conserva. El modelo principal mantiene todas las observaciones. La prueba reservada no se usa para decidir exclusiones ni seleccionar esta variante.

7. Evaluación del ajuste del modelo

Definimos sin ambigüedad $SC_{\text{tot}} = \sum (Y_i - \bar{Y})^2$, $SC_{\text{reg}} = \sum (\widehat{Y}_i - \bar{Y})^2$ y $SC_{\text{res}} = \sum \hat{u}_i^2$. Con intercepto,

$$SC_{\text{tot}} = SC_{\text{reg}} + SC_{\text{res}} = 566.8908 + 12.0247 = 578.9155.$$

$$R^2 = 1 - \frac{SC_{\text{res}}}{SC_{\text{tot}}} = 1 - \frac{12.0247}{578.9155} = 0.9792,$$
$$\bar{R}^2 = 1 - \frac{SC_{\text{res}}/(n-k)}{SC_{\text{tot}}/(n-1)} = 0.9780.$$

El modelo explica el 97.92 % de la variabilidad observada en el conjunto de ajuste. El RMSE de ajuste es 0.5779 s y el MAE 0.4642 s. El RMSE usa divisor n; el error estándar s usa divisor $n-k$. No son la misma cantidad. Un R^2 alto no garantiza predicciones correctas fuera del diseño ni valida los supuestos por sí solo.

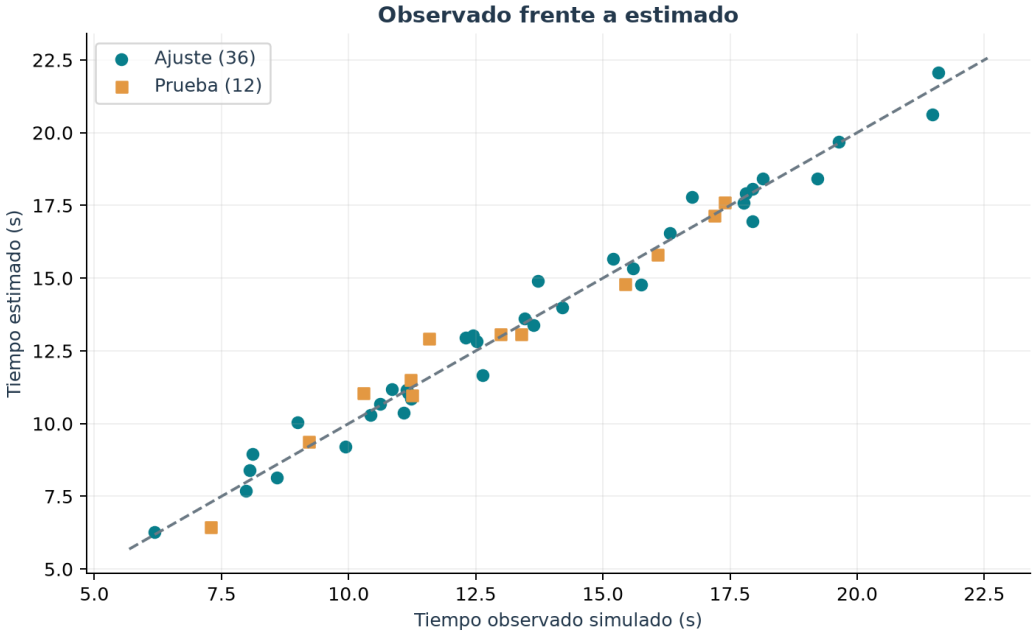


Figura 1: Comparación de tiempos observados simulados y estimados. La línea discontinua representa predicción perfecta.

8. Evaluación de los supuestos del modelo

1. **Linealidad y especificación.** Se justifican por la suma de costos de trabajo y escritura. Se inspeccionan residuos frente a ajustados y a cada regresora. RESET explora una desviación cuadrática, pero no descarta toda omisión o interacción posible.
2. **Exogeneidad y media condicional cero.** Son condiciones del generador porque el ruido se produce independientemente de W, V. En un benchmark real exigirían control experimental; los residuos por sí solos no las verifican.
3. **Homoscedasticidad.** El generador usa varianza constante; se contrasta con la versión de Koenker de la prueba de Breusch–Pagan y se revisa la dispersión residual. Se comparan además errores estándar HC3.
4. **Independencia.** El ruido se genera independientemente. Se usa el orden conservado de ejecución para revisar autocorrelación de primer orden; no se ordenan las filas por W o V antes del contraste. Ausencia de autocorrelación no implica independencia general.
5. **Variación y no colinealidad perfecta.** $n = 36 > k = 3$, las dos regresoras varían y rango$(X) = 3$. Para dos regresoras $VIF = 1/(1 - r^2_{WV}) = 1.0134$ en ambas pendientes, sin evidencia de inflación fuerte. En modelos con más regresoras se usa el R^2_j de cada regresión auxiliar.
6. **Normalidad de los errores.** Es parte de la simulación antes del redondeo, y se evalúa mediante Q-Q, Shapiro–Wilk y Jarque–Bera. La normalidad interesa para inferencia clásica exacta; no implica normalidad de W, V o de los tiempos marginales.

Los residuos de MCO están correlacionados a través de la matriz $I - H$ y tienen varianza $\sigma^2(1 - h_i)$. Por ello, las pruebas sobre residuos son diagnósticos aproximados; no deben confundirse con observación directa de errores iid. Los gráficos no muestran curvatura ni un embudo marcado, y el orden no exhibe una tendencia persistente.

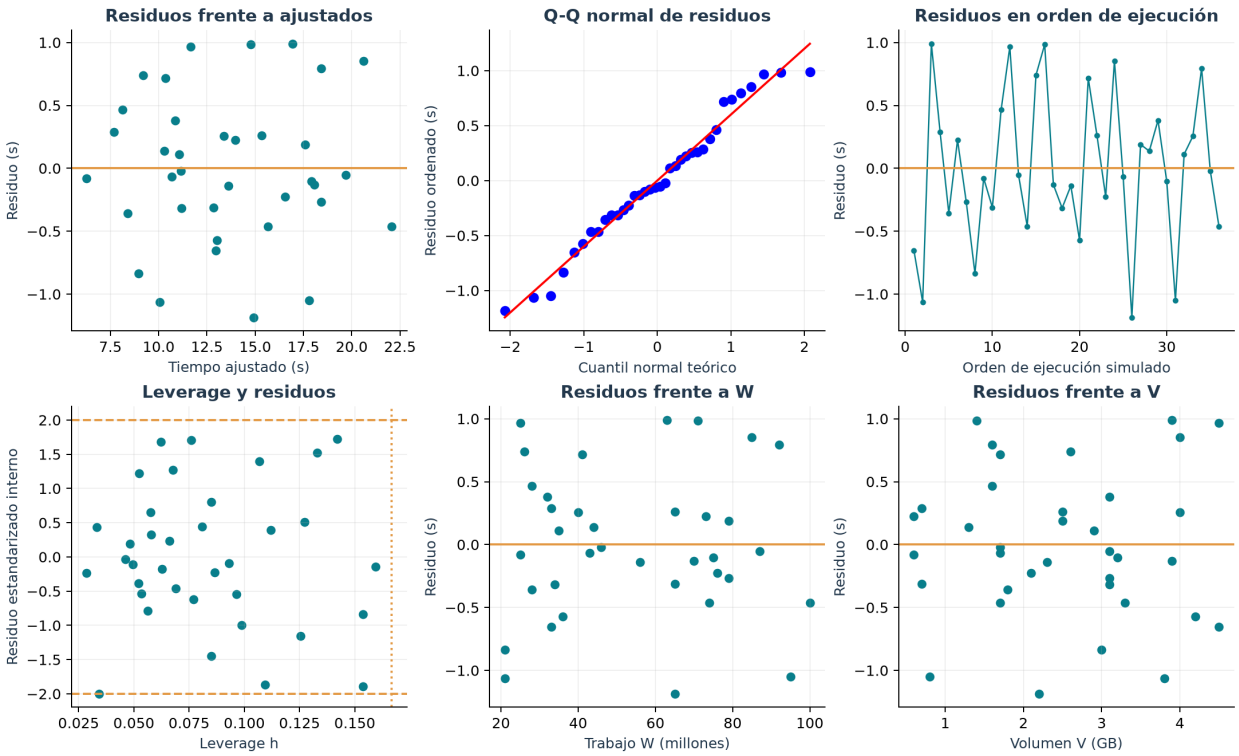


Figura 2: Diagnósticos con las 36 filas de ajuste. Las líneas de leverage y residuos son umbrales orientativos.

9. Pruebas estadísticas de los residuos

En cada prueba se fija $\alpha = 0.05$: se rechaza la hipótesis nula cuando $p < 0.05$. Los valores p no son probabilidades de que H_0 sea verdadera. Los diagnósticos se interpretan en conjunto con el diseño y los gráficos [3, 4].

Prueba	Estadístico	p	Decisión al 5 %
Shapiro-Wilk	0.9703	0.4340	No rechazar H_0
Jarque-Bera	0.5286	0.7677	No rechazar H_0
Koenker/Breusch–Pagan	1.1869	0.5524	No rechazar H_0
Breusch-Godfrey, orden 1	0.0189	0.8908	No rechazar H_0
RESET, potencia 2	0.0438	0.8356	No rechazar H_0

Normalidad. Shapiro–Wilk contrasta compatibilidad con una distribución normal. Jarque–Bera usa asimetría S y curtosis K:

$$JB = \frac{n}{6}\left(S^2 + \frac{(K-3)^2}{4}\right) \;\dot{\sim}\; \chi^2_2.$$

Ambos valores p exceden 0.05. No se detecta evidencia de no normalidad; no se demuestra que la distribución sea normal.

Varianza constante. La versión robusta de Koenker de Breusch–Pagan regresa $\hat{u}_i^2$ sobre $1, W_i, V_i$ y calcula $LM = nR^2_{\text{aux}} \dot{\sim} \chi^2_2$. Se obtiene $LM = 1.1869$ y $p = 0.5524$. No se rechaza homoscedasticidad. Se especifica esta versión para distinguirla de la formulación original sensible a normalidad [5].

Correlación serial. Breusch–Godfrey de orden 1 incorpora el residuo rezagado a la regresión auxiliar, conservando el orden de ejecución; $H_0 : \rho_1 = 0$ y $LM \dot{\sim} \chi^2_1$. El resultado es $LM = 0.0189$,

$p = 0.8908$. Durbin–Watson es 1.9018 y se presenta como descripción complementaria, sin atribuirle un valor p calculado. No se detecta autocorrelación de primer orden [6].

Especificación. RESET añade $\widehat{Y}_i^2$ al modelo y contrasta que su coeficiente sea cero mediante $F_{1,32}$. El resultado $F = 0.0438$, $p = 0.8356$ no indica necesidad de ese término. Puede haber otras formas de especificación incorrecta no detectadas. Las cinco pruebas son exploratorias, sin corrección por multiplicidad; su potencia es limitada con 36 registros.

10. Pruebas de hipótesis de los coeficientes de regresión

Para $j = 1, 2, 3$: $H_0 : \beta_j = 0$ frente a $H_1 : \beta_j \neq 0$. Se estima

$$\widehat{\mathrm{Var}}(\widehat{\boldsymbol{\beta}}) = s^2 (X^\mathsf{T} X)^{-1}, \quad t_j = \frac{\hat{\beta}_j}{ee(\hat{\beta}_j)}, \quad IC_{95\,\%}(\beta_j) = \hat{\beta}_j \pm t_{0.975,33}\, ee(\hat{\beta}_j).$$

Aquí $t_{0.975,33} = 2.0345$. Se rechaza H_0 si $|t_j| > 2.0345$ o si el valor p bilateral es menor que 0.05.

Parámetro	Estimación	Error est.	t	p	IC 95 %
β_1	1.414171	0.351106	4.0278	0.0003	$[0.6998, 2.1285]$
β_2	0.160782	0.004264	37.7068	1.031×10^{-28}	$[0.1521, 0.1695]$
β_3	1.385309	0.087537	15.8253	5.682×10^{-17}	$[1.2072, 1.5634]$

Las dos pendientes son significativas y positivas. El intercepto también resulta significativo, pero ello no valida una interpretación física fuera del rango. Las pruebas individuales se interpretan como inferencia nominal al 5 %, sin ajuste para contrastes múltiples. Como control de sensibilidad a heteroscedasticidad, los errores estándar HC3 son $(0.294287, 0.004984, 0.098330)$; las dos pendientes conservan $p < 0.05$ con HC3.

11. Prueba de hipótesis global del modelo

La hipótesis global es $H_0 : \beta_2 = \beta_3 = 0$ frente a que al menos una pendiente sea distinta de cero. El intercepto no forma parte de esta restricción. La tabla ANOVA es

Fuente	Suma de cuadrados	gl	Cuadrado medio	F
Regresión	566.8908	2	283.4454	777.8729
Residuos	12.0247	33	0.364385	
Total	578.9155	35		

$$F = \frac{SC_{\mathrm{reg}}/2}{SC_{\mathrm{res}}/33} = \frac{283.4454}{0.364385} = 777.8729 \quad \overset{H_0}{\sim} \quad F_{2,33}.$$

El valor crítico es $F_{0.95;2,33} = 3.2849$ y $p = 1.730 \times 10^{-28}$. Como F excede el valor crítico, se rechaza H_0: el modelo completo aporta explicación lineal respecto de un modelo con solo intercepto. Esto no significa que todos los supuestos estén demostrados ni que cada variable deba ser significativa individualmente; esa última conclusión requiere sus pruebas t.

12. Validación del modelo

12.1. Estrategia sin fuga de información

Las 12 filas de prueba permanecen fuera de la estimación, diagnósticos y selección. Sobre las 36 filas de ajuste se ejecuta validación cruzada de seis particiones: se permutan sus índices con semilla 20261029, se forman seis grupos de seis y cada grupo se predice con un modelo ajustado con las otras 30 filas. Cada fila obtiene una predicción fuera de su ajuste. No se eligieron variables ni hiperparámetros usando estos resultados.

$$RMSE = \sqrt{\frac{1}{m}\sum_{i=1}^{m}(Y_i - \widehat{Y}_i)^2}, \qquad MAE = \frac{1}{m}\sum_{i=1}^{m}|Y_i - \widehat{Y}_i|.$$

Para cada conjunto se usa $R^2 = 1 - \sum(Y - \widehat{Y})^2 / \sum(Y - \bar{Y}_{\text{conjunto}})^2$. La media de referencia de R^2 es la del conjunto evaluado; la predicción del modelo base, en cambio, es la media del entrenamiento correspondiente.

Evaluación	RMSE (s)	MAE (s)	R^2
Ajuste (36)	0.5779	0.4642	0.9792
Cruzada, fuera de ajuste (36)	0.6100	0.4816	0.9769
Base, cruzada (36)	4.0622	3.4355	-0.0262
Prueba reservada (12)	0.5707	0.4360	0.9658
Base, prueba (12)	3.2017	2.7825	-0.0762

Los resultados por partición son los siguientes. Las métricas agregadas anteriores se calculan juntando los 36 errores fuera de ajuste, no promediando los seis R^2.

Partición	m	RMSE (s)	MAE (s)
1	6	0.4753	0.3066
2	6	0.7830	0.6574
3	6	0.7288	0.6465
4	6	0.5550	0.4363
5	6	0.6836	0.5871
6	6	0.2949	0.2554

12.2. Interpretación de la prueba reservada

El RMSE de prueba es 0.5707 s, frente a 3.2017 s del modelo base. El MAE de prueba es 0.4360 s, y $R^2_{\text{prueba}} = 0.9658$. La cercanía con validación cruzada ($RMSE = 0.6100$ s) no sugiere una degradación grande en esta pequeña reserva. Los intervalos de predicción del 95 % incluyen 11 de los 12 tiempos observados (91.67 %). Esta fracción pequeña no permite estimar con precisión la cobertura real ni demostrar una cobertura nominal del 95 %.

Se conserva el modelo ajustado con 36 filas para mantener idénticos coeficientes en el informe y el HTML. No se reajusta con las 48 filas después de evaluar. En un proyecto real haría falta una validación independiente por sesión, equipo y régimen de trabajo; una partición aleatoria dentro de una misma máquina no garantiza transportabilidad.

13. Predicción mediante el modelo

Para $W_0 = 60$ y $V_0 = 2.5$, $\boldsymbol{x}_0 = (1, 60, 2.5)^{\mathsf{T}}$:

$$\widehat{T}_0 = 1.414171 + (0.160782)(60) + (1.385309)(2.5) = 14.5243 \text{ s}.$$

El factor de varianza es $h_0 = \boldsymbol{x}_0^{\mathsf{T}}(X^{\mathsf{T}}X)^{-1}\boldsymbol{x}_0 = 0.029315$. El error estándar para la media es $s\sqrt{h_0} = 0.1034$ s. Por tanto,

$$\begin{aligned} IC_{95\,\%}\{E(T_0 \mid \boldsymbol{x}_0)\} &= \widehat{T}_0 \pm t_{0.975,33}\, s\sqrt{h_0} \\ &= 14.5243 \pm (2.0345)(0.1034) = [14.3141, 14.7346] \text{ s}. \end{aligned}$$

Para una nueva ejecución individual se suma la variabilidad del nuevo error:

$$\begin{aligned} IP_{95\,\%}(T_{0,\text{nuevo}}) &= \widehat{T}_0 \pm t_{0.975,33}\, s\sqrt{1 + h_0} \\ &= [13.2783, 15.7703] \text{ s}. \end{aligned}$$

El intervalo individual es más amplio porque incluye incertidumbre sobre la media y fluctuación de una nueva ejecución. Son intervalos frecuentistas, condicionales al modelo y sus supuestos. No incluyen cambios de hardware o errores de especificación. El punto propuesto pertenece a la envolvente convexa del diseño de ajuste. El HTML distingue puntos dentro de esa envolvente, dentro de rangos marginales pero fuera de ella, y fuera de los rangos de ajuste; no recorta silenciosamente entradas ni intervalos.

14. Simulación y visualización

14.1. Experimento Monte Carlo reproducible

Para separar la variación de una muestra de la conducta repetida del estimador se conserva X de ajuste y se simulan $B = 5000$ vectores de tiempos con $\boldsymbol{\beta}^* = (2, 0.16, 1.20)^{\mathsf{T}}$ y $\sigma^* = 0.55$, usando semilla 20261030. En esta simulación auxiliar no se redondean los tiempos. Para cada repetición:

1. Generar $\boldsymbol{u}^{(b)} \sim N(\boldsymbol{0}, 0.55^2 I)$ y definir $\boldsymbol{Y}^{(b)} = X\boldsymbol{\beta}^* + \boldsymbol{u}^{(b)}$.
2. Estimar $\hat{\boldsymbol{\beta}}^{(b)}$ por MCO y $s_b^2 = SC_{\text{res},b}/33$.
3. Construir los tres intervalos t del 95 % y registrar si contienen el valor generador correspondiente.
4. Resumir medias, desviaciones y coberturas empíricas.

Coeficiente	Valor generador	Media MCO	DE entre ajustes	Cobertura 95 %
β_1	2.000000	2.000498	0.319906	0.9484
β_2	0.160000	0.160054	0.003863	0.9488
β_3	1.200000	1.198708	0.080508	0.9470

Las medias estimadas son cercanas a los valores generadores. Las coberturas están próximas a 0.95, coherentes con el modelo normal correcto. La desviación Monte Carlo de una cobertura cercana al 95 % es aproximadamente $\sqrt{0.95(0.05)/5000} = 0.0031$, por lo que diferencias de unas décimas de punto porcentual son esperables. Este experimento verifica el procedimiento bajo condiciones conocidas, no la validez física del escenario.

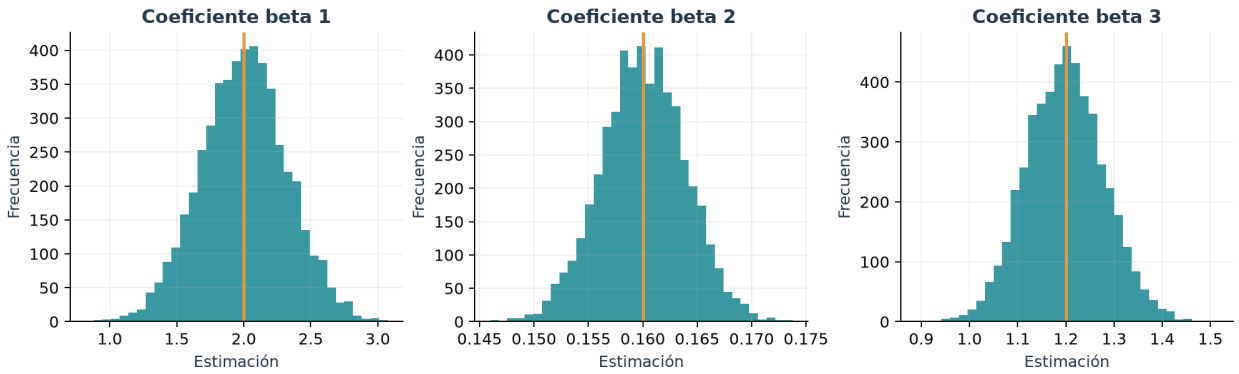


Figura 3: Distribución de los coeficientes en 5000 muestras; la línea vertical señala el parámetro generador.

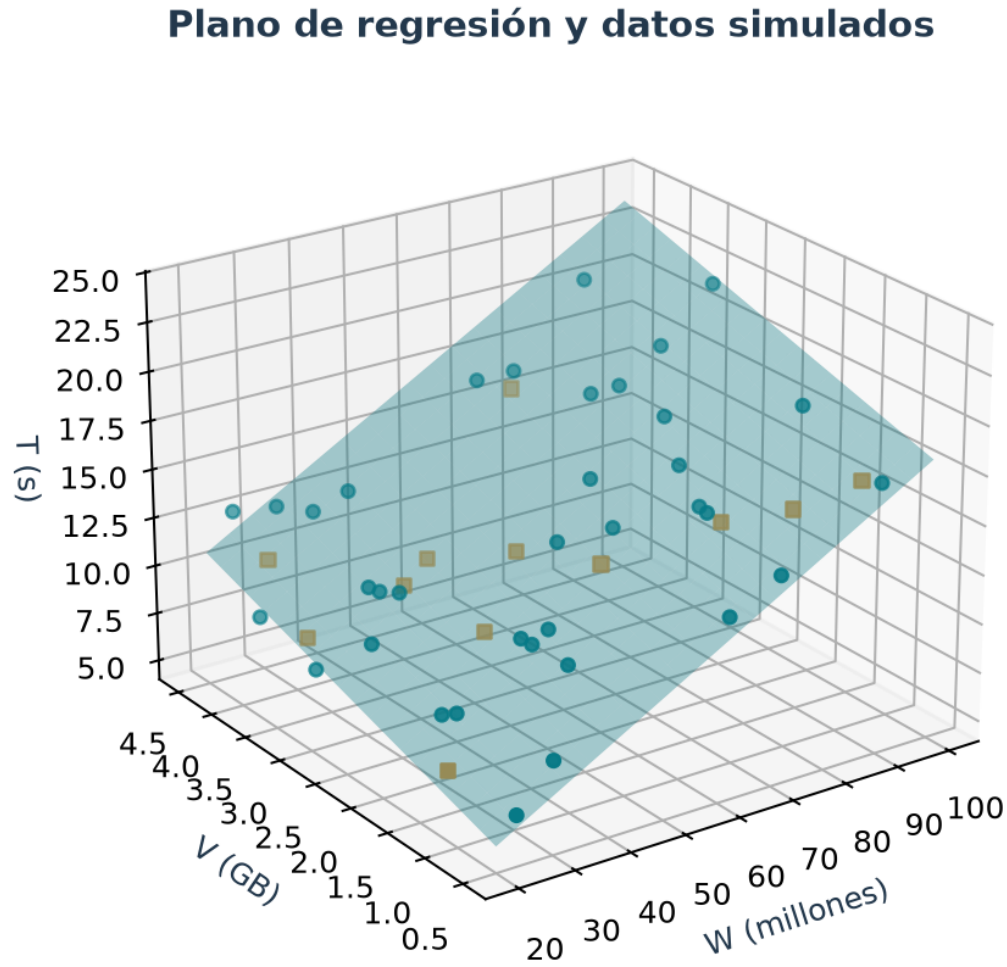


Figura 4: Plano estimado: trabajo, volumen y tiempo. Verde: ajuste; naranja: prueba.

14.2. Uso de la aplicación HTML

Abrir `modelo_interactivo.html` en un navegador. El archivo es autónomo, sin bibliotecas remotas ni servidor. Permite modificar W, V, consultar predicción e intervalos, visualizar la respuesta al variar W con V fijo, inspeccionar diagnósticos, ver todos los registros y descargar un CSV.

La sección de simulación permite cambiar una semilla y σ, generar otra muestra sobre el mismo diseño y volver a estimar MCO. Se informa el modelo simulado y su RMSE respecto de esa muestra. La simulación del navegador usa su propio generador determinista y Box–Muller; no pretende reproducir la secuencia PCG64 de NumPy. El experimento de 5000 repeticiones del informe se reproduce con el script Python. La muestra interactiva no modifica los coeficientes oficiales usados en predicción, tablas o diagnósticos. Así se distingue la simulación exploratoria del resultado evaluado.

15. Análisis y discusión de resultados

El trabajo acumulado y la escritura tienen asociaciones positivas claras con el tiempo. La estimación de trabajo (0.160782 s/millón) es cercana al valor generador de 0.16; la de escritura (1.385309 s/GB) difiere del 1.20 generador por variación muestral. Una muestra concreta no recupera exactamente parámetros poblacionales. El intercepto también fluctúa y no debe interpretarse físicamente en el origen sin datos allí.

El buen ajuste y los errores fuera de muestra pequeños son esperables porque los datos se generaron con una relación lineal de bajo ruido. Esto hace útil el ejemplo para aprender el procedimiento, pero limita cualquier afirmación sobre rendimiento de un equipo real. La ausencia de rechazos en diagnósticos no equivale a verificar todos los supuestos. La revisión de Cook muestra observaciones cuyo peso conviene discutir; suprimirlas por mejorar resultados produciría un análisis sesgado.

En mediciones reales puede crecer la varianza con la carga, aparecer dependencia térmica o cambiar la tasa de disco. Frente a heteroscedasticidad se revisarían HC3, transformaciones o mínimos cuadrados ponderados justificados; frente a dependencia, un diseño por bloques y métodos apropiados; frente a curvatura, términos adicionales justificados y validados. No se deben añadir términos solo para elevar R^2. Al aumentar hilos, cambiar arquitectura o extrapolar fuera del diseño, habría que recolectar nuevos datos.

16. Conclusiones

1. Se resolvió un ejercicio de regresión múltiple con interpretación computacional, estimando tres parámetros a partir de 36 observaciones simuladas y reservando 12 para prueba.
2. La ecuación $\widehat{T} = 1.414171 + 0.160782W + 1.385309V$ presenta pendientes positivas y significativas. El contraste global rechaza pendientes nulas simultáneas.
3. El ajuste obtiene $R^2 = 0.9792$ y $s = 0.6036$ s. Los diagnósticos no detectan las desviaciones específicas contrastadas al 5 %, pero no demuestran los supuestos. Se revisaron cuatro filas con influencia orientativa.
4. La validación cruzada obtiene RMSE de 0.6100 s y la prueba reservada 0.5707 s. El ejemplo de $W = 60, V = 2.5$ produce 14.5243 s, con IP del 95 % $[13.2783, 15.7703]$ s.
5. La simulación repetida apoya la consistencia del cálculo bajo el modelo generador. Antes de utilizar la ecuación en planificación real deben recolectarse benchmarks y validarse el entorno y el dominio de predicción.

17. Referencias bibliográficas

[1] Fiestas Flores, R. C. (s. f.). *Semana 9. Regresión lineal múltiple: MCO, ANOVA, coeficientes y supuestos del modelo*. Material del curso Modelos matemáticos de la ciencia II, Escuela Profesional de Computación Científica. Archivo `9.pdf`, 19 páginas, del proyecto de ChatGPT proporcionado por el usuario. Se consultaron especialmente las páginas 4–18.

[2] *Regresión Multiple.pdf* (s. f.). Extracto de texto sobre regresión múltiple, 224 páginas. Material del proyecto del curso proporcionado por el usuario. Se consultaron los capítulos 7 y 8 para estimación e inferencia, y el apartado sobre Breusch–Pagan para heteroscedasticidad. El fragmento no incluye portada editorial; se conserva su título de archivo sin inventar metadatos bibliográficos.

[3] NIST/SEMATECH. (s. f.). *e-Handbook of Statistical Methods: Check of assumptions*. https://itl.nist.gov/div898/handbook/pri/section2/pri245.htm. Consulta: 28 de octubre de 2026.

[4] Proyecto statsmodels. (s. f.). *Regression diagnostics and specification tests*. https://www.statsmodels.org/stable/diagnostic.html. Consulta: 28 de octubre de 2026.

[5] Proyecto statsmodels. (s. f.). *het_breuschpagan: Breusch–Pagan Lagrange Multiplier test for heteroscedasticity*. https://www.statsmodels.org/stable/generated/statsmodels.stats.diagnostic.het_breuschpagan.html. Consulta: 28 de octubre de 2026.

[6] Proyecto statsmodels. (s. f.). *acorr_breusch_godfrey: Breusch–Godfrey Lagrange Multiplier tests for residual autocorrelation*. https://www.statsmodels.org/stable/generated/statsmodels.stats.diagnostic.acorr_breusch_godfrey.html. Consulta: 28 de octubre de 2026.

A. Datos completos y residuos

Las filas 1–36 son de ajuste: su diferencia observado menos estimado es un residuo. Las filas 37–48 son de prueba: la diferencia es un error de predicción fuera de muestra. Las cifras se muestran a tres decimales. El CSV incluye además leverage, residuos estandarizados, Cook e intervalos a mayor precisión. Los diagnósticos de influencia solo se definen aquí para las filas usadas en el ajuste.

Cuadro 1: Los 48 registros y su estimación con el mismo modelo.

ID	Conjunto	W	V	T	$\widehat{T}$	$T-\widehat{T}$
1	ajuste	33	4.5	12.300	12.954	-0.654
2	ajuste	21	3.8	8.992	10.055	-1.063
3	ajuste	63	3.9	17.936	16.946	0.990
4	ajuste	33	0.7	7.977	7.690	0.287
5	ajuste	28	1.8	8.052	8.410	-0.358
6	ajuste	73	0.6	14.207	13.982	0.225
7	ajuste	79	3.1	18.144	18.410	-0.266
8	ajuste	21	3.0	8.110	8.947	-0.837
9	ajuste	25	0.6	6.186	6.265	-0.079
10	ajuste	65	0.7	12.523	12.835	-0.312
11	ajuste	28	1.6	8.597	8.133	0.464
12	ajuste	25	4.5	12.633	11.668	0.965
13	ajuste	87	3.1	19.643	19.697	-0.054
14	ajuste	74	1.7	15.204	15.667	-0.463
15	ajuste	26	2.6	9.937	9.196	0.741
16	ajuste	71	1.4	15.753	14.769	0.984
17	ajuste	70	3.9	17.941	18.072	-0.131
18	ajuste	34	3.1	10.859	11.175	-0.316
19	ajuste	56	2.3	13.465	13.604	-0.139
20	ajuste	36	4.2	12.448	13.021	-0.573
21	ajuste	41	1.7	11.078	10.361	0.717
22	ajuste	65	2.5	15.588	15.328	0.260
23	ajuste	76	2.1	16.316	16.543	-0.227
24	ajuste	85	4.0	21.476	20.622	0.854
25	ajuste	43	1.7	10.618	10.683	-0.065
26	ajuste	65	2.2	13.728	14.913	-1.185
27	ajuste	79	2.5	17.769	17.579	0.190
28	ajuste	44	1.3	10.426	10.289	0.137
29	ajuste	32	3.1	11.235	10.854	0.381
30	ajuste	75	3.2	17.804	17.906	-0.102
31	ajuste	95	0.8	16.747	17.797	-1.050
32	ajuste	35	2.9	11.171	11.059	0.112
33	ajuste	40	4.0	13.641	13.387	0.254
34	ajuste	92	1.6	19.217	18.423	0.794
35	ajuste	46	1.7	11.145	11.165	-0.020
36	ajuste	100	3.3	21.599	22.064	-0.465
37	prueba	25	4.0	11.238	10.975	0.263
38	prueba	41	2.2	10.287	11.054	-0.767
39	prueba	72	1.3	15.435	14.791	0.644
40	prueba	91	0.8	17.182	17.154	0.028
41	prueba	37	3.0	11.210	11.519	-0.309
42	prueba	81	1.0	16.072	15.823	0.249
43	prueba	21	1.2	7.285	6.453	0.832
44	prueba	51	2.5	12.982	13.077	-0.095
45	prueba	57	1.8	13.385	13.072	0.313
46	prueba	44	3.2	11.579	12.922	-1.343
47	prueba	22	3.2	9.218	9.384	-0.166
48	prueba	68	3.8	17.389	17.611	-0.222

B. Intervalos y errores en la prueba reservada

Los límites son intervalos de predicción individuales nominales del 95 %, calculados con t_{33} y varianza de una nueva observación. No son intervalos simultáneos para todas las filas.

ID	T	$\widehat{T}$	Error	Límite inferior	Límite superior
37	11.238	10.975	0.263	9.682	12.268
38	10.287	11.054	-0.767	9.802	12.306
39	15.435	14.791	0.644	13.522	16.061
40	17.182	17.154	0.028	15.842	18.465
41	11.210	11.519	-0.309	10.263	12.775
42	16.072	15.823	0.249	14.534	17.111
43	7.285	6.453	0.832	5.148	7.758
44	12.982	13.077	-0.095	11.832	14.323
45	13.385	13.072	0.313	11.821	14.323
46	11.579	12.922	-1.343	11.668	14.175
47	9.218	9.384	-0.166	8.105	10.664
48	17.389	17.611	-0.222	16.337	18.886

C. Trazabilidad, notación y reproducción

Relación con los materiales. Se adopta la FRP/FRM con intercepto β_1, las fórmulas MCO en desviaciones de la página 10 de `9.pdf`, la varianza residual con $n-k$, VIF, determinación, pruebas t y F. El extracto `Regresión Multiple.pdf` respalda la interpretación parcial y la inferencia. La validación reservada, los diagnósticos programados y el laboratorio HTML amplían el ejercicio solicitado.

Aclaraciones de consistencia. En las diapositivas 14 y 16 de `9.pdf` se intercambian los símbolos SCE y SCR entre algunas expresiones. En este informe se definen explícitamente SC_{reg} y SC_{res}; siempre $R^2 = SC_{\text{reg}}/SC_{\text{tot}}$ y $F = (SC_{\text{reg}}/2)/(SC_{\text{res}}/33)$. La derivada parcial correcta de β_2 en la diapositiva 11 es respecto de X_2. En VIF, lo relevante es $|r| \to 1$, pues una correlación no puede ser mayor que 1. Finalmente, se escribe "no rechazar" una hipótesis en lugar de "aceptarla" como verdad demostrada.

Reproducción del cálculo. Ejecutar `reproducir.py` desde la carpeta del paquete. Se requieren NumPy, SciPy, pandas, statsmodels y Matplotlib. La orden `python reproducir.py` crea la carpeta `recalculado/` con datos, resultados y figuras; no altera los entregables originales. Versiones usadas: numpy 2.5.4, scipy 1.18.1, statsmodels 0.15.0, pandas 3.1.0, matplotlib 3.11.2. El script deja fijadas las semillas 20261028 (datos), 20261029 (particiones) y 20261030 (Monte Carlo). `resultados.json` conserva cifras con precisión completa. El HTML contiene una copia de esos mismos resultados.

Compilación. El archivo principal es `informe/main.tex`; cargarlo con la carpeta `images/` en un proyecto de LaTeX y compilar con pdfLaTeX, dos veces para resolver el índice y referencias. También puede usarse Tectonic. No se necesitan archivos bibliográficos externos. El PDF compilado permite revisar el documento sin instalar LaTeX.